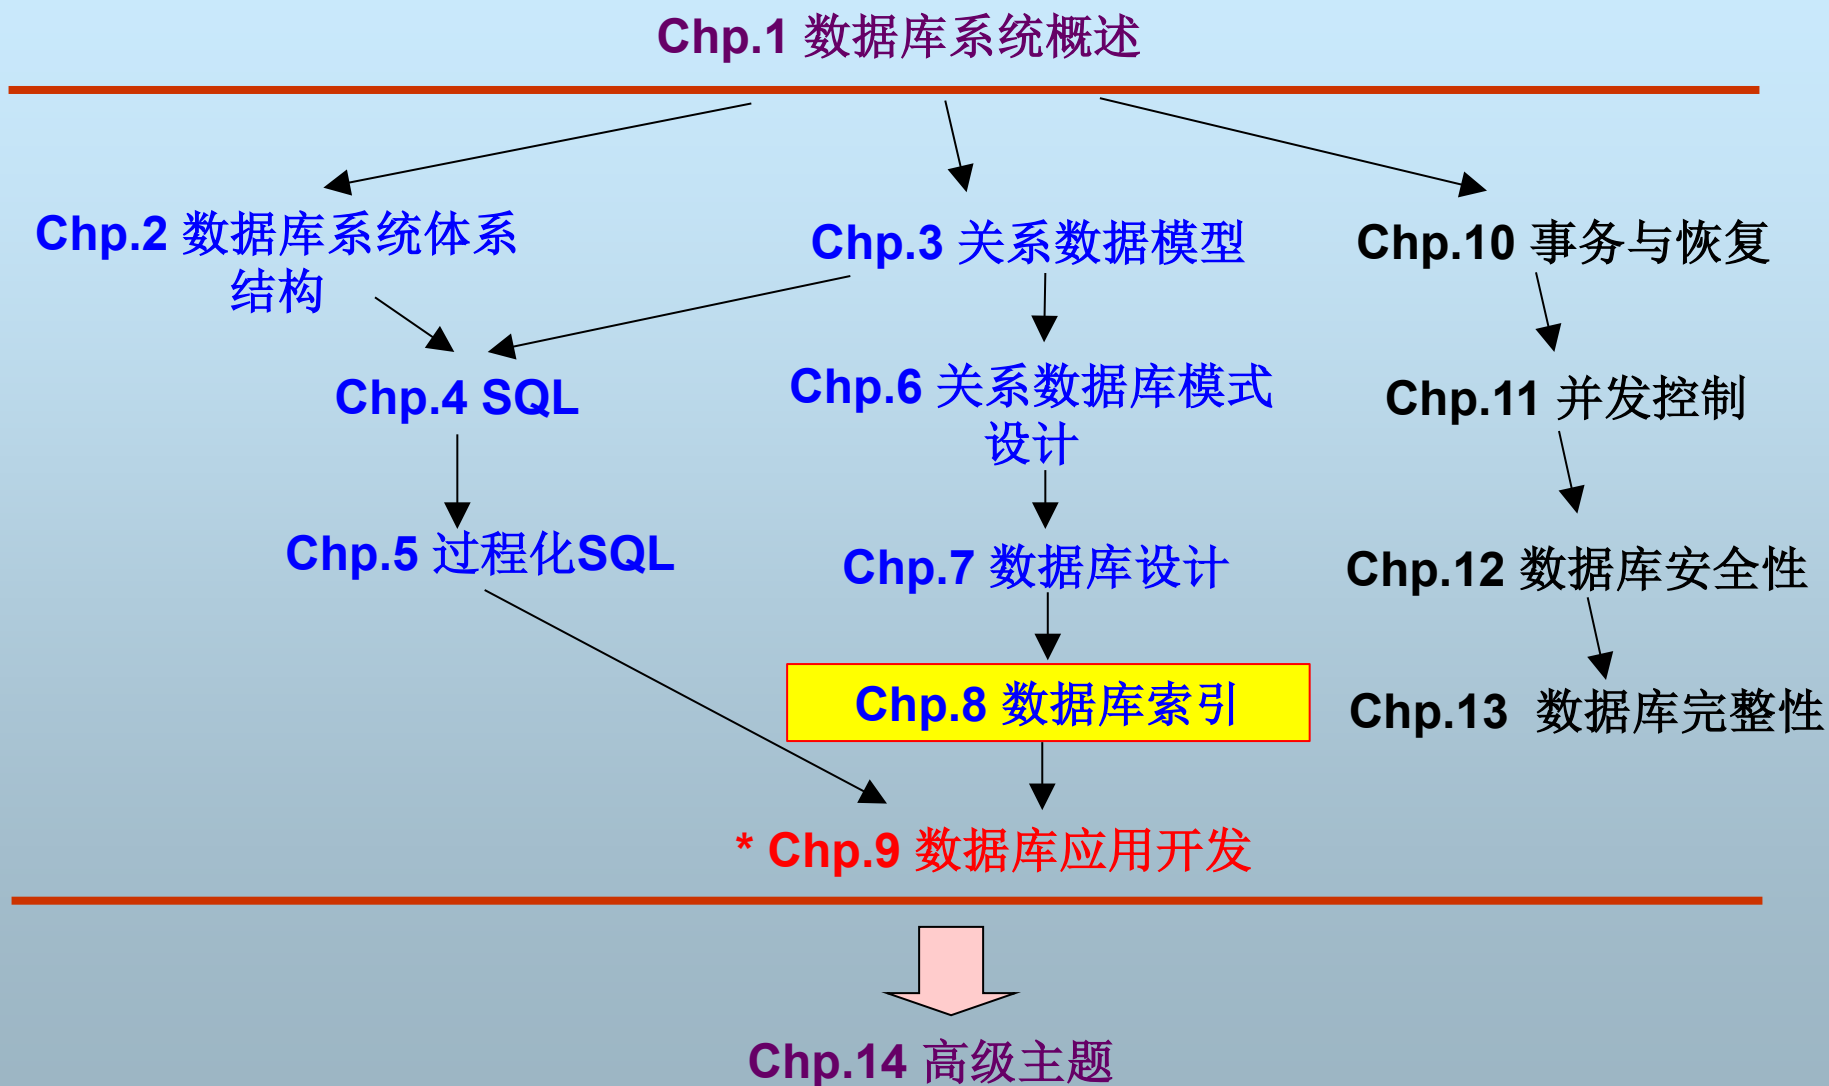



第8章 数据库索引



课程知识结构



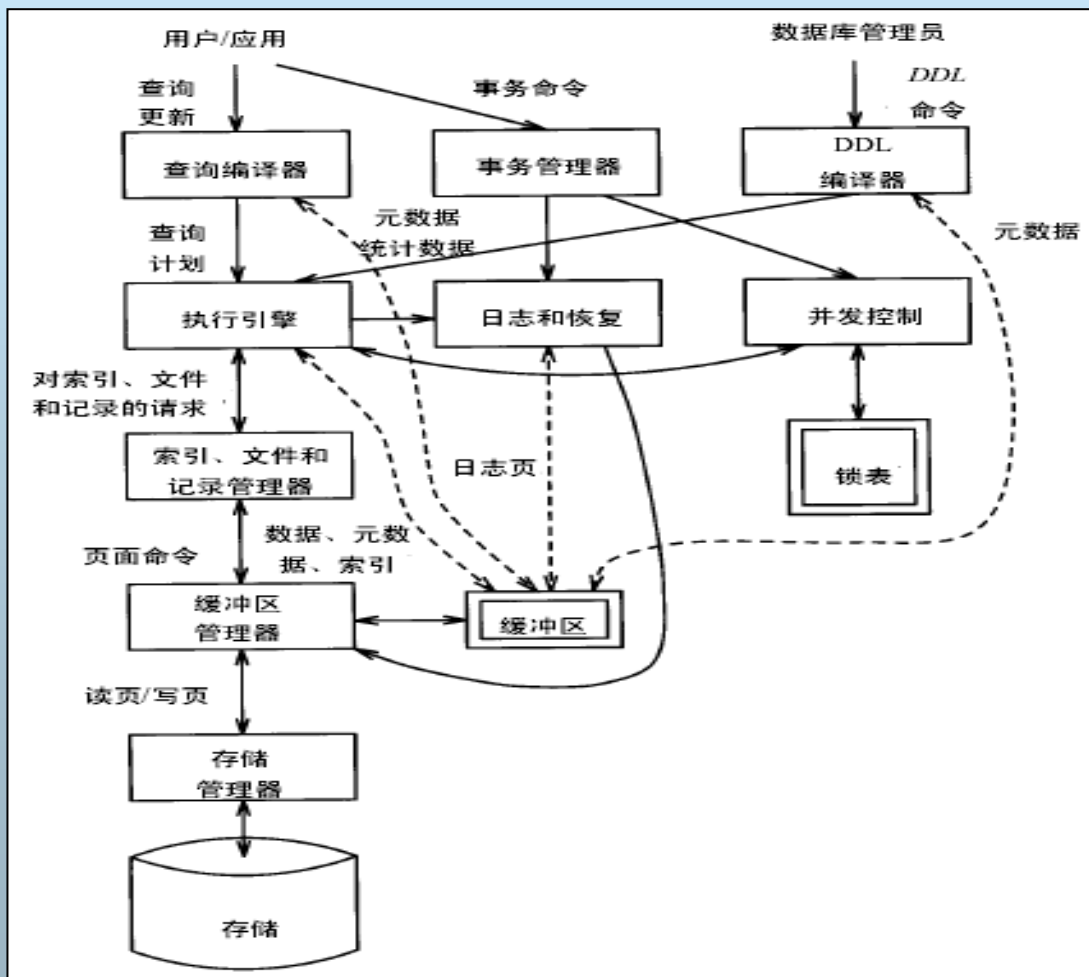
为什么DBMS底层需要按页存取？



- 一次磁盘访问的延迟包括：
 - 寻道时间 (10-40ms)
 - 旋转延迟 (~4ms, 7200RPM)
 - 传输时间 (<1ms)
 - 其它延迟 (忽略不计)
- 磁盘最小物理存取单位
 - 扇区 (512B)
- DBMS和OS的逻辑存取单位
 - 页 (磁盘块) —— 若干连续扇区
 - 16KB——MySQL
 - 8KB——MS SQL Server
 - 减少数据存取时的寻道时间

数据库为什么需要索引?

■ 没有索引，数据查询效率低



若 page size = 8 KB, page I/O 10ms


1 MB (128 pages): 1.28 s

128 MB (16384 pages): 163.8 s

1 GB (131072 pages): 1310.7 s \approx 21.8 min

索引的动机:


提高按查找键 (Search Key) 查找的性能, 将记录请求快速定位到页地址



外存索引 vs. 内存索引


■ 外存索引

- 数据在外存，e.g. SSD or HDD
- 目标是减少I/O代价
- 数据库索引通常指外存索引



■ 内存索引

- 数据在内存，e.g. DRAM or NVM
- 目标是减少内存cacheline访问次数



主要内容

- 顺序文件上的索引
- 辅助索引
- B+树
- 散列表 (Hash Tables)

一、顺序文件上的索引

■ 顺序文件

- 记录按查找键排序

Search key



10	
20	

30	
40	

50	
60	


70	
80	

90	
100	

1、密集索引(Dense Index)

- 每个记录都有一个索引项
- 索引项按查找键排序

1、密集索引(Dense Index)




1、密集索引(Dense Index)

查找：
查找索引项，
跟踪指针即可

Dense Index

Sequential File



1、密集索引(Dense Index)

■ 为什么使用密集索引？

- 记录通常比索引项要大
- 索引可以常驻内存
- 要查找键值为K的记录是否存在，不需要访问磁盘数据块

■ 密集索引缺点？

- 索引占用太多空间



用稀疏索引改进


2、稀疏索引(Sparse Index)

- 仅部分记录有索引项
- 一般情况：为每个数据块的第一个记录建立索引

2、稀疏索引(Sparse Index)

Sparse Index

Sequential File



2、稀疏索引(Sparse Index)

■ 有何优点？

- 节省了索引空间
- 对同样的记录，稀疏索引可以使用更少的索引项

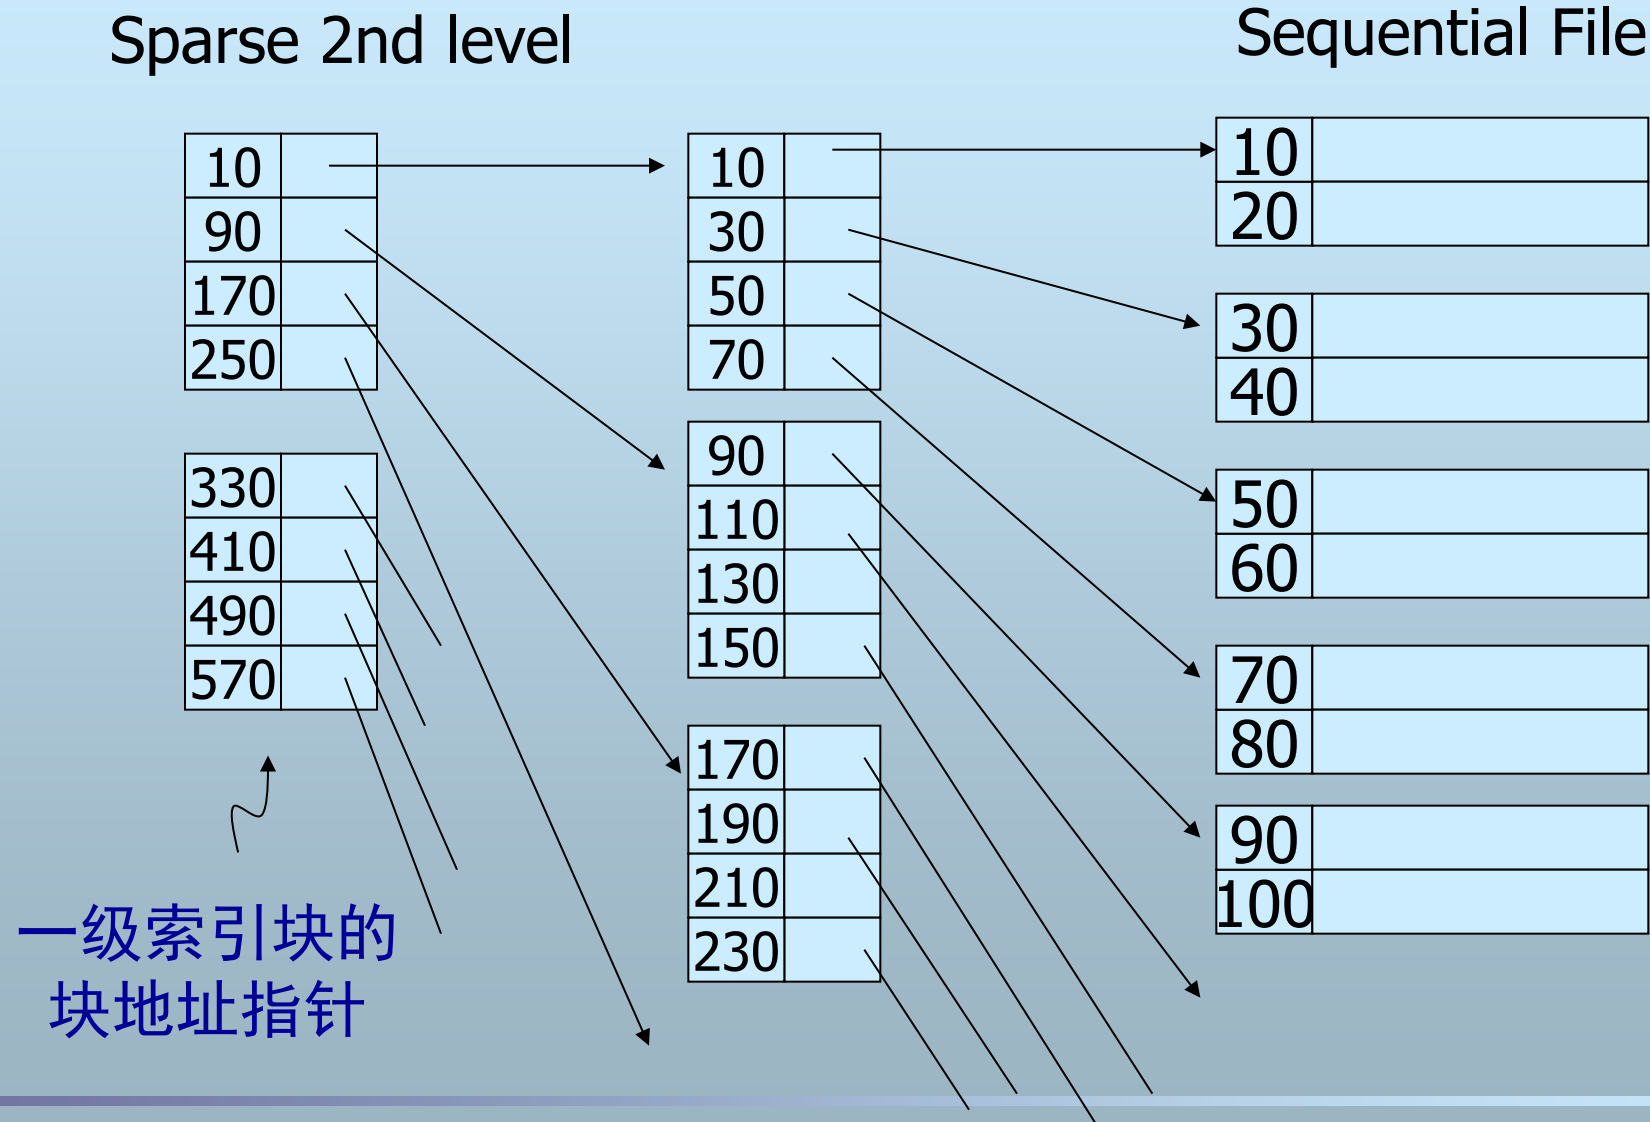
■ 有何缺点？

- 对于“是否存在键值为K的记录？”，需要访问磁盘数据块

3、多级索引(Multi-level Index)

- 索引上再建索引
 - 二级索引、三级索引.....

3、多级索引(Multi-level Index)



3、多级索引(Multi-level Index)

■ 多级索引的好处？

- 一级索引可能还太大而不能常驻内存
- 二级索引更小，可以常驻内存
- 减少磁盘I/O次数

3、多级索引(Multi-level Index)

例：一块=4KB。一级索引10,000个块，每个块可存100个索引项，共40MB。二级稀疏索引100个块，共400KB。

按一级索引查找(二分查找)：平均 $\lg 10000 \approx 13$ 次I/O定位索引块，加一次数据块I/O，共约14次I/O

按二级索引查找：定位二级索引块0次I/O，读入一级索引块1次I/O，读入数据块1次I/O，共2次I/O

3、多级索引(Multi-level Index)

- 当一级索引过大而二级索引可常驻内存时有效
- 二级索引仅可用稀疏索引
 - 思考：二级密集索引有用吗？
- 一般不考虑三级以上索引
 - 维护多级索引结构
 - 有更好的索引结构——B⁺树

二、辅助索引

■ 主索引（Primary Index）

- 顺序文件上的索引
- 记录按索引属性值有序
- 根据索引值可以确定记录的位置

■ 辅助索引（Secondary Index）

- 数据文件不需要按查找键有序
- 根据索引值不能确定记录在文件中的顺序

1、辅助索引概念

```
MovieStar(name char(10) PRIMARY KEY, address char(20))
```

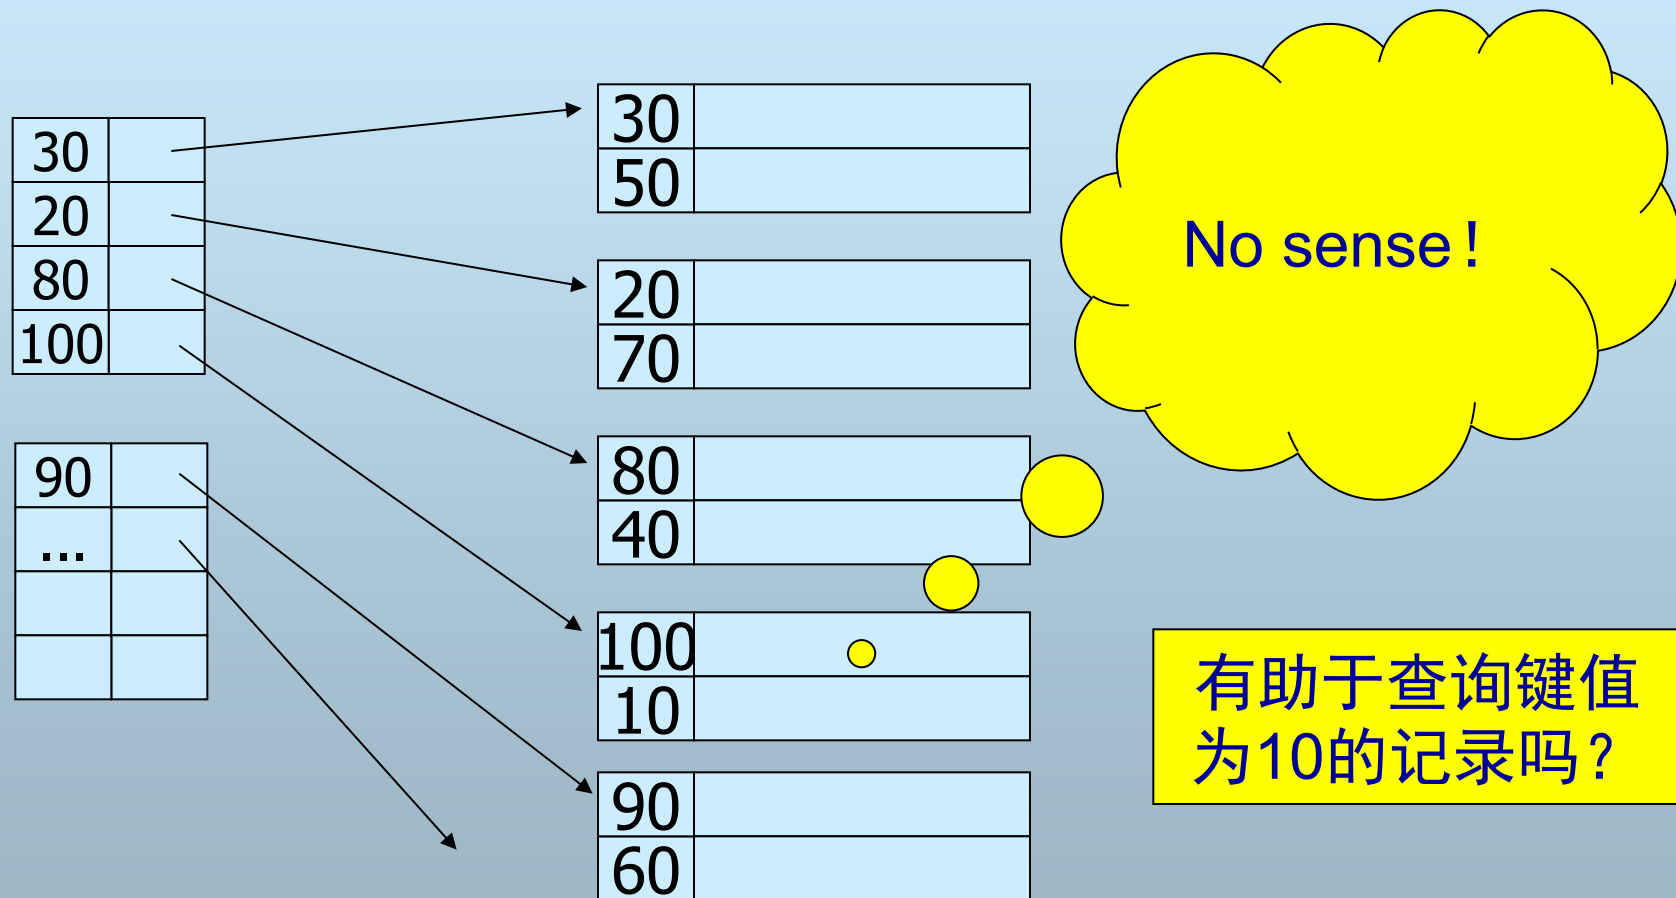
- **Name**上创建了主索引，记录按**name**有序
- **Address**上创建辅助索引

```
Create Index adIndex On MovieStar(address)
```

1、辅助索引概念


- 辅助索引只能是密集索引
 - 稀疏的辅助索引有意义吗？

1、辅助索引概念

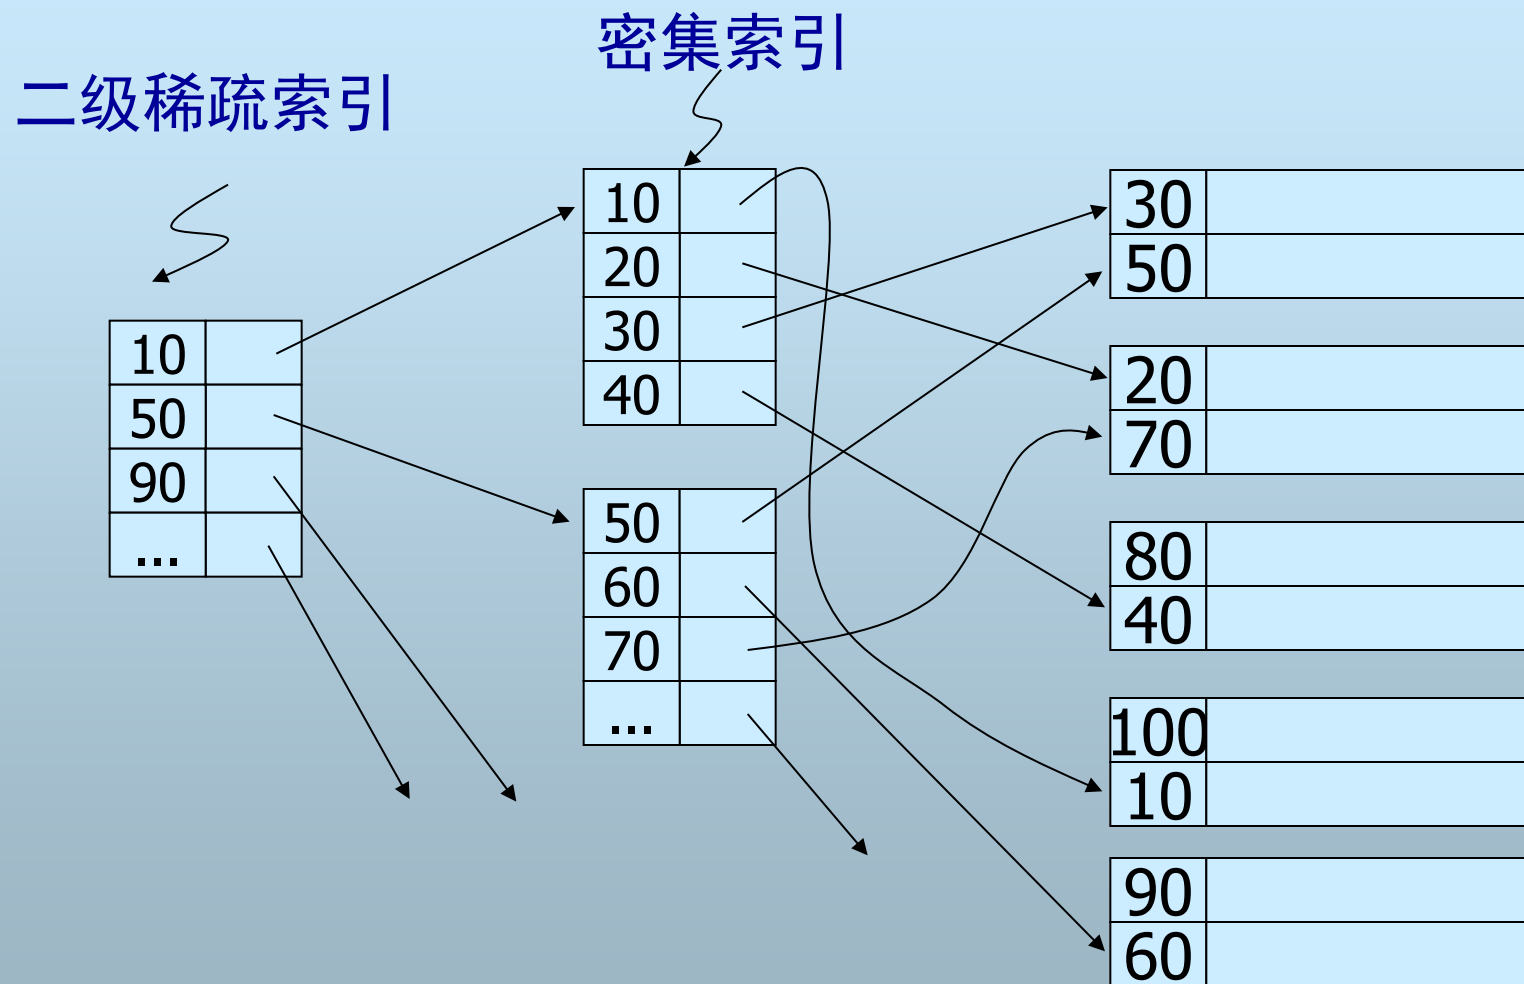


2、辅助索引设计

密集索引



2、辅助索引设计




问题

- 重复键值怎么处理？

3、辅助索引中的间接桶

- Indirect Bucket
- 重复键值
 - 采用密集索引浪费空间
- 间接桶
 - 介于辅助索引和数据文件之间

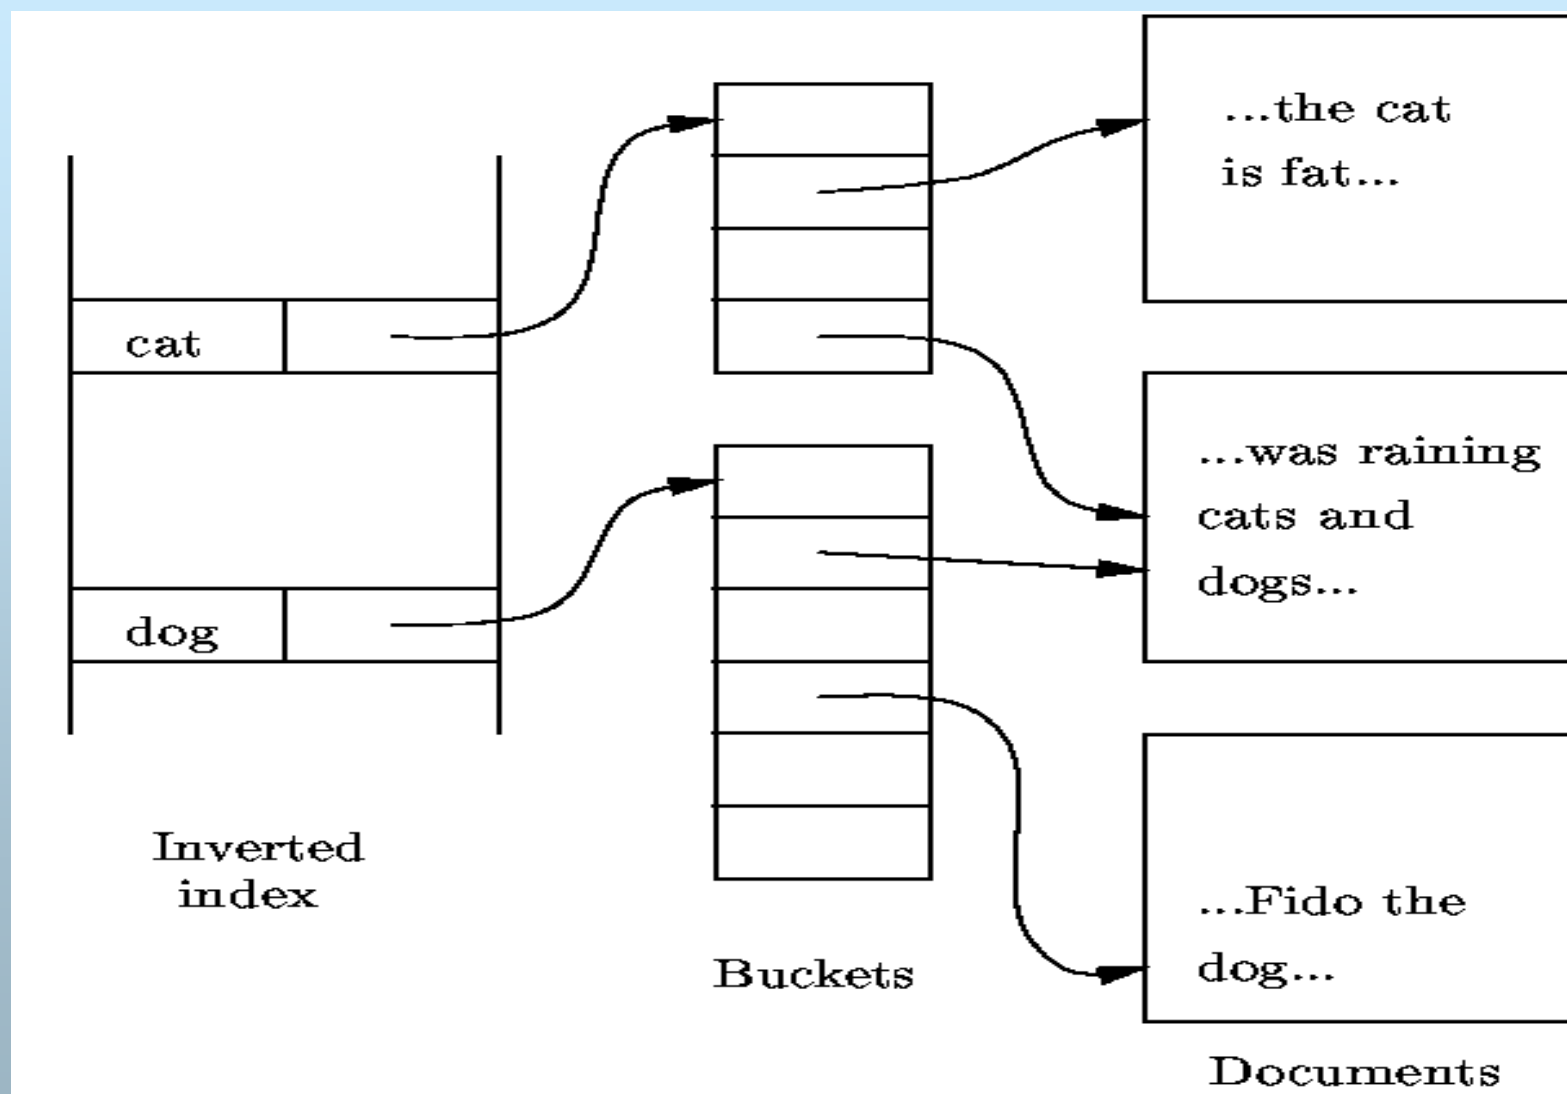
3、辅助索引中的间接桶



4、倒排索引(Inverted Index)

- 应用于文档检索，与辅助索引思想类似
- 不同之处
 - 记录→文档
 - 记录查找→ 文档检索
 - 查找键→ 文档中的词
- 思想
 - 为每个检索词建立间接桶
 - 桶的指针指向检索词所出现的文档

4、倒排索引(Inverted Index)



4、倒排索引(Inverted Index)

